

Conv: ~~the~~ ~~kernel~~ ~~current~~ $I_{in} \times I_{in} \times I_{out}$

$$FLOPS = 2 \cdot (C_{in} \cdot k \times k \cdot C_{out} \cdot I_{out} \cdot I_{out})$$

$$MEM = MEM_{in} + MEM_{out} + MEM_w =$$

$$= (C_{in} \times k \times k \times C_{out})$$

$$(C_{in} \times I_{in} \times I_{in}) + (C_{out} \cdot I_{out} \cdot I_{out}) +$$

$$+ (C_{in} \times k \times k \times C_{out}) \cdot 4 \text{ bytes}$$

MAX POOL ($k \times k$); stride 2 $p=1$

$$FLOPS = 0 - \text{exclusion}$$

$$MEM = MEM_{in} + MEM_{out} =$$

$$= (C_{in} \times I_{in} \times I_{out}) + (C_{out} \times I_{out} \times I_{out}) \cdot 4 \text{ bytes}$$

RELU $\max(0, x)$ in place

$$FLOPS = 0$$

$$MEM = MEM_{in} = MEM_{out}$$

$$MEM = C_{in} \times I_{in} \times I_{out} \cdot 4 \text{ bytes}$$

Batch Norm $MEM = 0$ параметры не вычисляются

группы не перекомбинируются

Batch Norm

$$FLOPS = 2 \cdot C_{in} \cdot I_{out} \cdot I_{out}$$

$$MEM = 4 \cdot C_{in} \cdot 4 \text{ bytes}$$

$$MEM = (4 \cdot C_{in}) + (C_{in} \times I_{in} \times I_{in}) \cdot 4 \text{ bytes}$$

$$Time_{comp} = \frac{Ops. (Flops)}{perf\ peak.}$$

$$T = \theta_{launch} + \theta_{mem} \cdot N(S; B) + \theta_{comp} F(S, B)$$

Global Avg Pool

$$FLOPS = (C_{in} \cdot S_{in} \cdot S_{in}) \leftarrow \text{отсюда}$$

$$MEM = MEM_{in} + MEM_{out}$$

$$MEM = (C_{in} \cdot S_{in} \cdot S_{out} + (C_{in})) \text{ байт}$$

Linear.

$$Flops = 2 MAC = 2 \cdot (C_{in} \times C_{out})$$

где c - одномерный вектор, кол-во элем.

$$MEM = MEM_{in} + MEM_{out}$$

$$MEM = (C_{in} + C_{out}) \cdot \text{байты}$$

$$1) \text{ conv } 3 \rightarrow 32, s=2, p=7(12) \\ \text{in } [3, 3, 3] \text{ out } [32, \frac{3}{2}, \frac{3}{2}]$$

$$2) \text{ relu() seg ymenenit} \\ \text{max pool } (k=3, s=2, p=1) \\ \text{in } [32, \frac{3}{2}, \frac{3}{2}] \rightarrow [32, \frac{3}{4}, \frac{3}{4}]$$

$$3) \text{ conv } (32 \rightarrow 64, k=5, s=1, p=2) \\ \text{in } [32, \frac{3}{4}, \frac{3}{4}] \rightarrow [64, \frac{3}{8}, \frac{3}{8}]$$

$$\text{relu() seg yme} \\ 4) \text{ conv } (k=3, 64 \rightarrow 128, s=2, p=1) \\ [64, \frac{3}{8}, \frac{3}{8}] \rightarrow [128, \frac{3}{8}, \frac{3}{8}]$$

$$\text{relu() seg yme} \\ 5) \text{ conv } (128 \rightarrow 256, k=3, s=1, p=1) \\ [128, \frac{3}{8}, \frac{3}{8}] \rightarrow [256, \frac{3}{8}, \frac{3}{8}]$$

$$\text{relu() seg yme} \\ 6) \text{ conv } (256 \rightarrow 256, k=3, s=2, p=1) \\ [256, \frac{3}{8}, \frac{3}{8}] \rightarrow [256, \frac{3}{16}, \frac{3}{16}]$$

$$\text{relu() seg yme} \\ \text{CAP} \\ 7) \text{ conv } (256 \rightarrow 512, k=1, s=1, p=0) \\ [256, \frac{3}{16}, \frac{3}{16}] \rightarrow [512, \frac{3}{16}, \frac{3}{16}]$$

$$\text{relu() seg yme} \\ 8) \text{ CAP (1)} \\ \text{out } (512 \times 1 \times 1) \rightarrow [512, \frac{3}{16}, \frac{3}{16}] \rightarrow 512$$

$$9) \text{ linear } 512 \rightarrow$$

$$\text{relu} \\ 10) \text{ linear } 256 \rightarrow$$

$$1) \text{ FLOPS}$$

$$\text{FLOPS}$$

$$2) \text{ FLOPS}$$

$$3) \text{ FLOPS}$$

$$4) \text{ FLOPS}$$

$$5) \text{ FLOPS}$$

$$6) \text{ FLOPS}$$

$$7) \text{ FLOPS}$$

$$8) \text{ FLOPS}$$

$$9) \text{ FLOPS}$$

$$10) \text{ FLOPS}$$

$$\text{FLOPS} \\ + 6400 \\ + 1024 \\ + 1024 \\ + 262$$

9) linear (512, 256)
512 → 256

relu

10) linear (256, 100)
256 → 100

$$1) \text{FLOPS}_{\text{conv}} = [2 \cdot 3 \cdot 4 \cdot 4 \cdot \frac{S}{2} \cdot \frac{S}{2} \cdot 32]$$

$$\text{FLOPS}_{\text{relu}} = 0$$

2) FLOPS max pool = 0 - operation

$$3) \text{FLOPS}_{\text{conv}} = [2 \cdot 32 \cdot 5 \cdot 5 \cdot \frac{S}{4} \cdot \frac{S}{4} \cdot 64]$$

$$4) \text{FLOPS}_{\text{conv}} = [2 \cdot 64 \cdot 3 \cdot 3 \cdot \frac{S}{8} \cdot \frac{S}{8} \cdot 128]$$

$$5) \text{FLOPS} = [2 \cdot 128 \cdot 1 \cdot 1 \cdot \frac{S}{8} \cdot \frac{S}{8} \cdot 256]$$

$$6) \text{FLOPS} = [2 \cdot 256 \cdot 3 \cdot 3 \cdot \frac{S}{16} \cdot \frac{S}{16} \cdot 512]$$

$$7) \text{FLOPS} = [2 \cdot 256 \cdot 1 \cdot 1 \cdot \frac{S}{16} \cdot \frac{S}{16} \cdot 512]$$

$$8) \text{FLOPS}_{\text{cap}} = 512 \cdot \frac{S}{16} \cdot \frac{S}{16}$$

$$9) \text{FLOPS}_{\text{lin}} = 2 \cdot 512 \cdot 256$$

$$10) \text{FLOPS}_{\text{lin}} = 2 \cdot 256 \cdot 100$$

$$\text{FLOPS} = 2352 \cdot S^2 +$$

$$+ 6400 \cdot S^2 + 9216 \cdot S^2 +$$

$$+ 1024 \cdot S^2 + 9216 \cdot S^2 +$$

$$+ 1024 \cdot S^2 + 2 \cdot S^2 =$$

$$= 262144 + 51200 \cdot S$$

суммарное количество операций

Linear (512, 256) при

если на вход тензор

с размерами 512x512x3

элементов.

Peak CPU MEM.

активации (промежуточные тензоры
веса (параметры
буферов)

Веса:

$$\text{conv1} = 7 \cdot 7 \cdot 3 \cdot 32 = 4704 \text{ p.}$$

$$\text{conv2} = 5 \cdot 5 \cdot 32 \cdot 64 = 51200 \text{ p.}$$

$$\text{conv3} = 3 \cdot 3 \cdot 64 \cdot 128 = 73728 \text{ p.}$$

$$\text{conv4} = 1 \cdot 1 \cdot 128 \cdot 256 = 32768 \text{ p.}$$

$$\text{conv5} = 3 \cdot 3 \cdot 256 \cdot 256 = 589824 \text{ p.}$$

$$\text{conv6} = 1 \cdot 1 \cdot 256 \cdot 512 = 131072 \text{ p.}$$

$$\text{fc1} = 512 \cdot 256 = 131072 \text{ p.}$$

$$\text{fc2} = 256 \cdot 100 = 25600 \text{ p.}$$

$$\text{total} = 1039968 \text{ p} \approx 4500 \text{ байт} = 41598725 = 4.16 \text{ MB}$$

Активации (peak пропектор
при максим. разрезении)

$$\text{in} = (B, 3, S, S')$$

$$\text{после conv1} + \text{relu} (B, 32, \frac{S}{2}, \frac{S}{2}) \rightarrow$$

$$\rightarrow (B \cdot 32 \left(\frac{S}{2}\right)^2 \cdot 4) \text{ байт}$$

$$\text{после pool1} (B, 32, \frac{S}{4}, \frac{S}{4}) \rightarrow B \cdot 32 \cdot \left(\frac{S}{4}\right)^2 \cdot 4$$

$$\text{после conv2} + \text{relu} (B, 64, \frac{S}{4}, \frac{S}{4}) \rightarrow B \cdot 64 \cdot \left(\frac{S}{4}\right)^2 \cdot 4$$

Peak buffer req.

$$\text{Peak activation} = B \cdot 64 \cdot \frac{S^2}{16} \cdot 4 \text{ байт}$$

после conv2

более точный расчёт:

после conv1 - $B \cdot 32 \cdot \frac{S^2}{4} \cdot 4 \text{ байт} = 32 \cdot S^2 \text{ байт}$.

после pool1: $(B \cdot 32 \cdot \frac{S}{4} \cdot \frac{S}{4}) \cdot 4 = B \cdot 32 \cdot \frac{S^2}{16} \cdot 4 = B \cdot 8 \cdot S^2 \text{ байт}$

реальный peak определяется max, поэтому то conv out может быть ограничено после pool1

Peak Mem(S, B) = $B \cdot \max(32 \cdot \frac{S^2}{4}, 8 \cdot \frac{S^2}{16})$

$\cdot 4 \text{ weight} = 32 \cdot B \cdot S^2 + 4 \cdot \frac{16}{16} B$

после conv + relu $[B, 32, \frac{S}{2}, \frac{S}{2}]$

pool1: $[B, 32, \frac{S}{4}, \frac{S}{4}]$

conv2 $[B, 64, \frac{S}{4}, \frac{S}{4}]$

Внимательно смотрите MEMORY (должна быть точная)!

$MEM = 4 (\sum_{f=32} \text{Activations}_f) + 8 (\sum \text{Indices})$

+ 4 Params.

и т.д.

у которого Max Pool

$\text{Ind } S/64 = B \cdot \text{Cont} \cdot S \cdot S$ разм типа
 $\text{int64}.$

$\text{int64} = 8 \text{ байт}.$

число по размерам: $\frac{1}{4} \cdot B \cdot 32 \cdot \frac{S}{4} \cdot \frac{S}{4}$

по индексам: $8 \cdot B \cdot 32 \cdot \left(\frac{S}{4}\right)^2$ байт

потребует памяти больше,
чем S умножения. $\text{FLOPS} \approx 0$

Bytes Moved (Read + Write)

Чтение весов относительно
по байтам, если веса в кэш
 $W = 4, 16 \text{ Мб}$

для которого след:

conv

read input $B \cdot 3 \cdot S^2 = 12 B S^2$

read weight $P = 4704 \cdot 4 = 18816$

write out: $B \cdot 32 \cdot \left(\frac{S}{2}\right)^2 \cdot 4 =$
 $= 32 B S^2$

и т.д.

то, что я не учла!