

Deep Learning on a Data Diet: Finding Important Examples Early in Training

Mansheej Paul, Surya Ganguli

Балаба Софья

Актуальность

Обучение нейронных сетей сводится к подбору гиперпараметров на данных больших объёмов. Данные часто зашумлены и вероятно не все одинаково полезны. Тогда давайте найдём такое подмножество обучающей выборки $\subset$ исходного, которые позволяет получить результаты, сопоставимые с теми, которые были достигнуты на основе всего множества данных.

Вопросы, на которые авторы отвечают в статье:

- какая часть данных избыточна
- какие примеры важны для обобщения
- и как их найти?

Что проверяют:

как отдельные примеры и подмножества обучающих примеров влияют на процесс обучения.

Что предложили авторы

Давайте посчитаем такую ранжирующую метрику для на всей обучающей выборке, которая сможет отсортировать обучающие примеры по вкладу в ассигасу (будем считать её на ранних стадиях обучения)

тогда мы сможем удалить часть данных (имеющих наименьшее значения), тем самым повысить эффективность обучения, за счёт уменьшения множества обучающих точек. которые ещё и будут сравнимы по качеству с сеткой обученной на всех данных.

Ранжирующая метрика EL2N:

$$\|p - y\|_2$$

- вторая норма абсолютной разницы вероятностей модели по классам и one-hot

Эксперимент

- 1) считаем ранжирующую метрику (EL2N) для каждой точки на ранних этапах обучения (20-ая) *
- 2) ранжируем примеры в соответствии метрики
- 3) выбираем фракцию данных (эффективность падает после 0.5) с наибольшим скором
- 4) завершаем полный цикл обучения на подмножестве
- 5) profit: качество на тесте сопоставимо с обучением на всем множестве.

*проводится ($n=10$ измерений), затем усредняются, чтобы нивелировать шум

Что им позволяет сделать такое предположение

Интуитивно понятно, что большой вклад вносят сложные примеры, у которых вектор градиентов больше по норме.

GraNd включает сумму градиентов по всем логитам классов

Авторы заменяют эту сложную сумму на норму вектора ошибки предсказания GraNd (Gradient Norm)

$$\chi_t(x, y) = \mathbb{E} \left\| \sum_k \nabla_{f^{(k)}} \ell(f_t(x), y)^T \psi_t^{(k)}(x) \right\|_2.$$

Если бы векторы градиентов по разным классам $\{\psi_t^{(k)}(x)\}_k$ были коррелированы, то норма их суммы не равнялась бы сумме норм

$$\mathbb{E} \|p(w_t, x) - y\|_2$$

Ортогональность градиентов по классам — это ключевое геометрическое свойство ландшафта потерь, которое позволяет заменить трудоемкое вычисление градиентов (GraNd) на простое вычисление ошибки предсказания (EL2N), сохраняя при этом способность ранжировать важность данных.

Related work

NTK и Forgetting Loss

Методология:


- Вычисляется косинусное расстояние между матрицами Грама NTK на разных шагах обучения
- Скорость сходимости к константе = скорость обучения ядра

Ключевые наблюдения:


- Высокая скорость NTK → сложные примеры, которые модель активно аппроксимирует
- Низкая скорость NTK → примеры с экстремальной сложностью (возможно, шум/ошибки разметки)

Аналогия авторов статьи:

- считать скорость сравнивая подмножества данных
- предложенный лосс, можно также вычислить на ранних стадиях обучения только для обучающих примеров.



Сколько эпох достаточно для измерения?



Подвыборка топ 1000 примеров

Что измеряем:


- Ошибку на тесте после обучения на этих подмножествах
- В зависимости от того, когда вычисляли EL2N (spawning time)

Вывод

- Примеры с высоким EL2N дают лучшую обобщающую способность
- Можно рано определить важные данные

Ключевой вклад

Аналогично удалению примеров, которые редко «забываются» в процессе обучения, достигая на выходе той же точности. Авторы статьи делают то же самое только через призму обучающий примеров, опираясь на локальную информацию (по подвыборке) на начальном этапе обучения




1 строка: fraction dataset = 0.5
Получилось достичь того же качества на половине данных

Это позволяет выделить два важных свойства:

- важность примера отражается в локальных характеристиках ландшафта функции потерь уже после нескольких эпох
- а ранжирование примеров по степени их важности сохраняется на протяжении всего процесса обучения.

Вывод



- Ранние тренировочные сигналы — надежный индикатор важности данных.
- GraNd и EL2N, вычисленные на ранних стадиях, работают не хуже Forgetting Score. = эффективный прунинг без полного обучения.
- Баланс между удалением шума и сохранением сложности — ключ к успеху.

Спасибо за внимание!

Референсная реализация авторов: https://github.com/mansheej/data_diet